

POLITECHNIKA WROCŁAWSKA  
WYDZIAŁ INFORMATYKI I TELEKOMUNIKACJI



---

## Widzenie komputerowe

---

Sprawozdanie z laboratorium

AUTOR

**Michał Sztandera - Kolanek**

nr albumu: **259042**

kierunek: **Inżynieria systemów**

*10 stycznia 2023*

### Streszczenie

Zaproponowano własną sieć neuronową do predykcji kart gry planszowej "Gloomhaven". Jakość sieci zestawiono z modelem liniowym.

## 1 Wstęp – opis problemu

W dzisiejszych czasach gry planszowe, póki co szczególnie poprzez pomocnicze aplikacje, dążą do cyfryzacji. Możliwe, że w przyszłości w gry planszowe będzie się grało na odległość - częściowo poprzez komputer, częściowo fizycznie, na przykład przy stole. Niezbędne będzie wtedy monitorowanie stołu przy pomocy kamery lub cykliczne wykonywanie zdjęć, tak aby gracze grający stacjonarnie i zdalnie mogli widzieć to samo. Podsumowaniem laboratorium jest program, który dla podanego zdjęcia karty z gry planszowej "Gloomhaven", zwróci nazwę tej karty. Jako że ta gra planszowa obejmuje ponad 1000 kart, skupiono się na 10 podstawowych kart postaci "myślap" - ich nazwy będą predykowane.

## 2 Opis rozwiązania

### 2.1 Dane

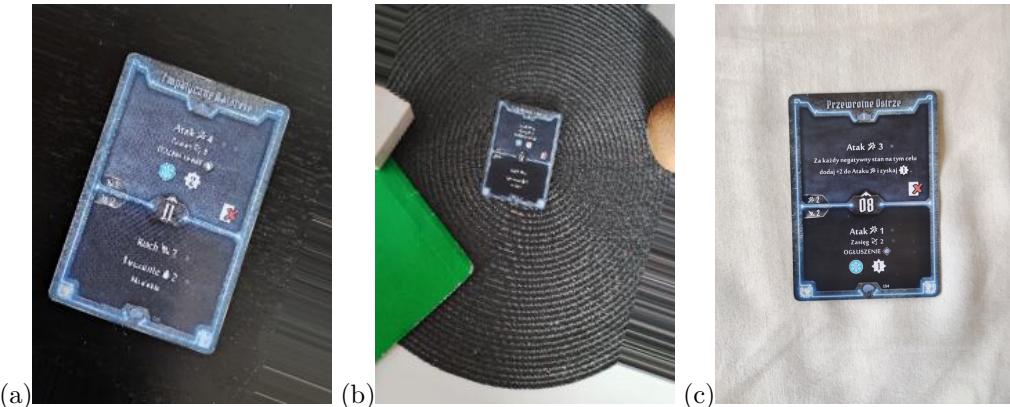
Zbiór danych uzyskano poprzez wykonanie 10 fotografii każdej karty w różnych miejscach oraz 10 fotografii tych samych miejsc, tym razem bez karty. Użyto przedstawionego na zajęciach laboratoryjnych programu służącego do generowania obrazów przy pomocy biblioteki OpenCV. Dokonano nieznacznych modyfikacji tego programu i wykorzystano go do wygenerowania 50 obrazów dla każdego zdjęcia. W ten sposób uzyskano zbiór zawierający 5500 obrazów, 500 dla każdej z 11 klas, w formacie jpg. Zbiór uczący obejmuje 4125, a zbiór walidacyjny 1375 obrazów. Obrazy zapisane zostały w oddzielnych folderach. Nazwa każdego folderu odpowiada nadanym etykietom. W tabeli 1 podano nazwy etykiet wraz z przyporządkowanymi im numerami, które odpowiadają wyjściom sieci neuronowej opisanej w punkcie 2.2.

Numer	Etykieta
0	brak karty
1	ciemnosc nocy
2	empatyczne natarcie
3	gryzaca horda
4	pasozytniczy wpływ
5	ped
6	przerazajace ostrze
7	przewrotne ostrze
8	slabosc umyslu
9	sprzerzenie zwrotne
10	uleglosc

Tabela 1: Przykłady obrazów z wygenerowanych: (a) i (b) oraz przykład oryginalnego obrazu (c)

Zdjęcia zostały wstępnie przetworzone. Zredukowano ich wymiary do 290 x 217, a kolory do skali odcieni szarości. To pozwoliło ustalić rozmiar danych wejściowych na takie, które sieć neuronowa była w stanie w skończonym czasie przetworzyć na osobistym laptopie.

Przykładowe obrazy (przed zmianą ich kolorystyki na odcień szarości) przedstawia rysunek 1.



Rysunek 1: Przykłady obrazów z wygenerowanych i (a) i (b) oraz przykład oryginalnego obrazu (c)

## 2.2 Algorytm rozpoznawania

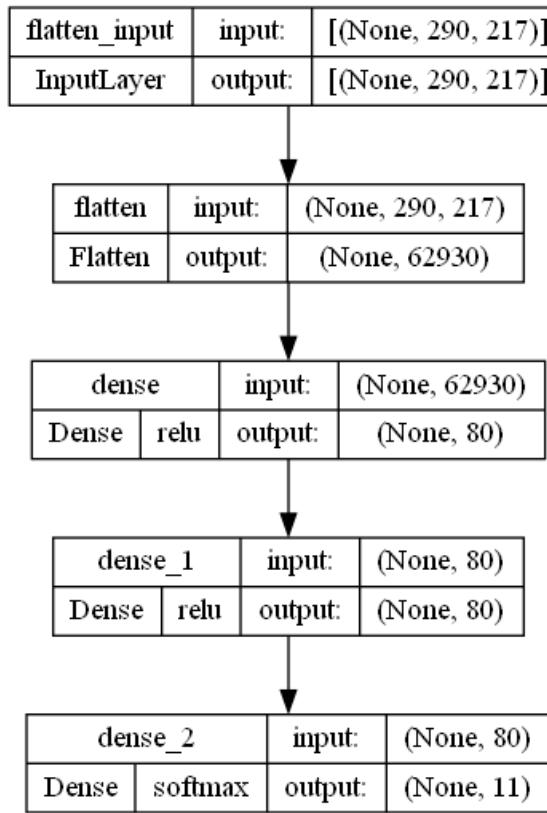
Zadanie rozpoznawania wykonywać będzie głęboka sieć neuronowa własnego projektu (klasyfikator A). Jest to nieznaczna modyfikacja sieci przedstawionej na zajęciach laboratoryjnych. Strukturę tej sieci przedstawia rysunek 2.

Liczba wyjść sieci jest równa liczbie klas. Aktywacją ostatniej warstwy jest zatem funkcja *softmax*. Wszystkie pozostałe parametry konfiguracyjne sieci są praktycznie identyczne jak użyte na laboratorium - wykorzystano dwie zamiast jednej warstwy ukrytej z aktywacją poprzez funkcję *relu*. Kod sieci udostępniłem w archiwum. Dla porównania korzystam z modelu liniowego (klasyfikator B) przygotowanego na zajęciach laboratoryjnych. Jakość rozpoznawania oceniono z wykorzystaniem macierzy pomyłek. W celu uproszczenia rozważań, odnotowywany będzie jedynie odsetek elementów leżących poza diagonalą, ponieważ jest to równoznaczne z odsetkiem nieprawidłowo zaklasyfikowanych obrazów.

## 3 Badania symulacyjne

### 3.1 Cel i plan badania

Celem badawczym jest sprawdzenie, jakie wyniki zwróci sieć (klasyfikator C) o identycznej strukturze jak sieć ucząca się i testowana na obrazkach o większych wymiarach, w jaki sposób większa szczegółowość obrazków wpłynie na skuteczność predykcji. W tym celu wygenerowano obrazki o wymiarach 580 x 434, czyli cztery razy większe względem tych o wymiarach 290 x 217. Niezdecydowano się na dużo większy wymiar z uwagi na ograniczenie jakim jest osobisty laptop służący do przeprowadzenia eksperymentów. Rezultaty zostaną porównane z sytuacją, gdy obrazy w zbiorze uczącym będą o wymiarach 290 x 217, dla klasyfikatora A oraz klasyfikatora B. Na obu tych zestawach danych sieci uczyły się przez tyle samo epok.



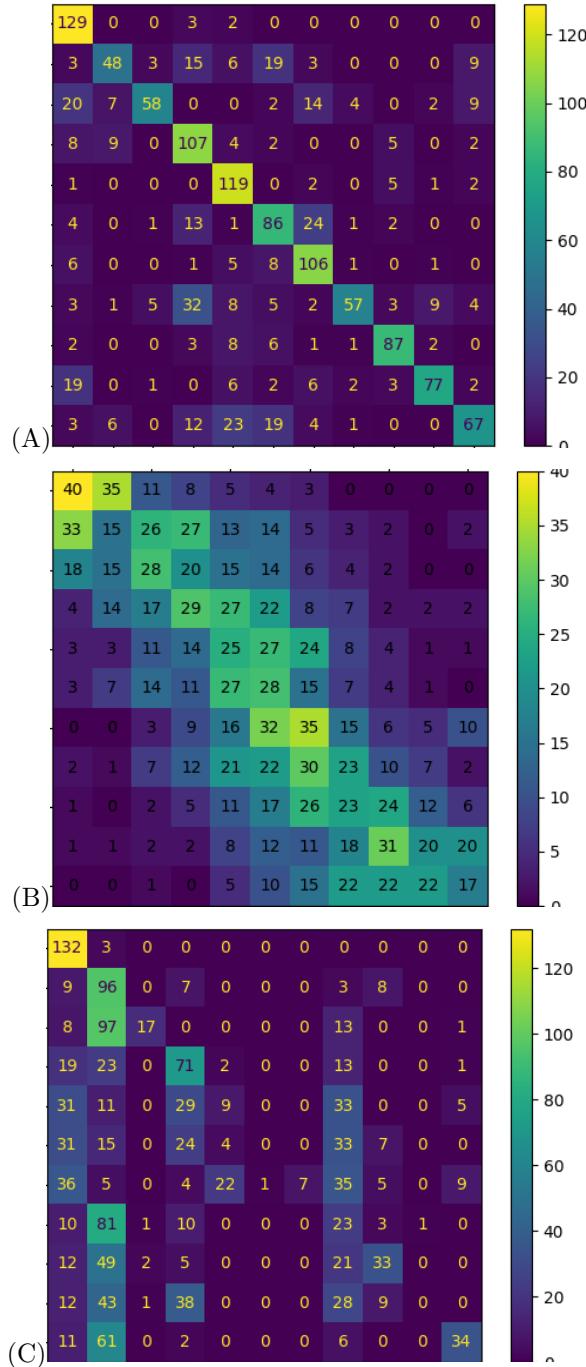
Rysunek 2: Struktura proponowanej sieci neuronowej

### 3.2 Wyniki eksperymentów

Zdecydowanie najmniejszą skuteczność w klasyfikacji obrazów uzyskał klasyfikator B - 20,65%. Skuteczność klasyfikatora C wyniosła 30,7%. Największą skuteczność uzyskał klasyfikator A - 68,43%. Na rysunku 3 przedstawione zostały macierze pomyłek z podziałem dla każdego klasyfikatora, wyznaczone przy użyciu zbioru walidacyjnego. W tabeli 2 podano procent prawidłowych rozpoznań, wyliczonych jako proporcja liczby prawidłowych rozpoznań do liczby wszystkich elementów tego zbioru. W ramach dodatkowego porównania, tabela została uzupełniona o procent prawidłowych rozwiązań, który średnio uzyskałby klasyfikator losowy.

Klasyfikator	Skuteczność predykcji
klasyfikator losowy	9,09%
klasyfikator A	68,43%
klasyfikator B	20,65%
klasyfikator C	30,7%

Tabela 2: Klasyfikatory i skuteczność ich predykcji



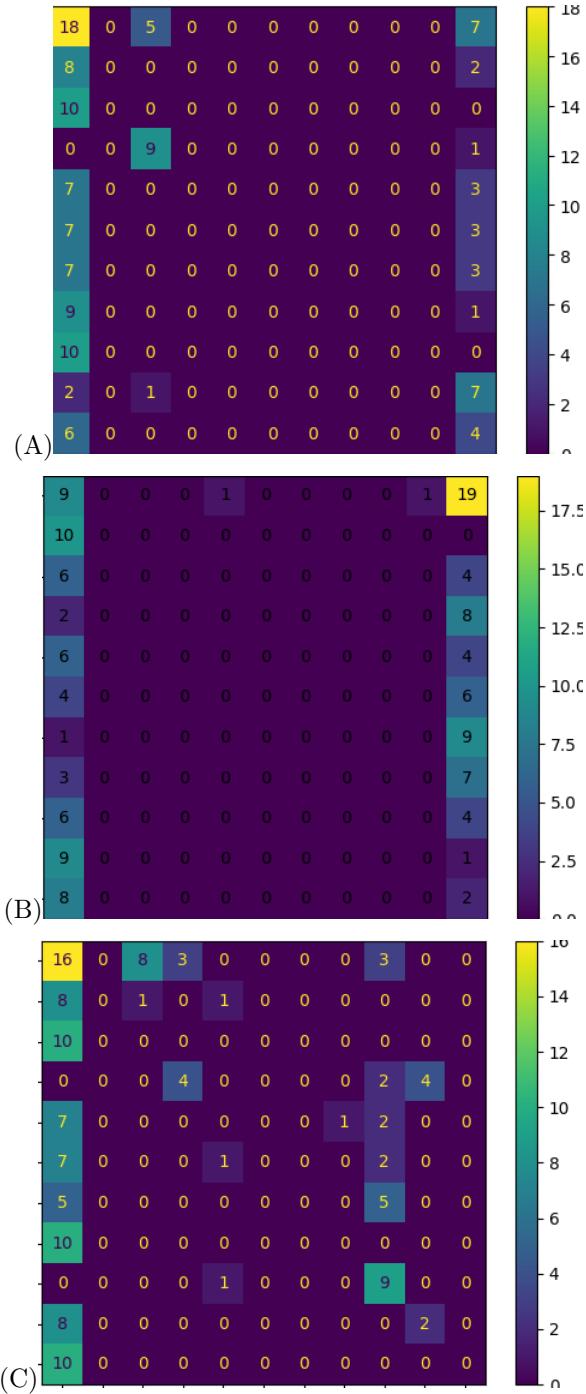
Rysunek 3: Macierze pomyłek prezentujące wyniki eksperymentu bazującego na zbiorze walidacyjnym, dla: klasyfikatora A (A), klasyfikatora B (B), klasyfikatora C (C). Na osi poziomej predykowane etykiety obrazów, na osi pionowej prawdziwe wartości, etykiety w kolejności pokazanej w tabeli 1

### 3.3 Weryfikacja skuteczności

Aby zweryfikować, czy proponowane klasyfikatory będą z podobną skutecznością klasyfikować obrazy spoza zbiorów uczącego i walidacyjnego, wygenerowano 130 dodatkowych obrazów na podstawie dodatkowo wykonanych zdjęć. Na 30 obrazach znajdują się karty z innej gry planszowej - "Agricoli", powinny być one zaklasyfikowane jako "brak karty". W tabeli 3 podano procent prawidłowych rozpoznań wyliczonych jako proporcja liczby prawidłowych rozpoznań do liczby wszystkich elementów zbioru walidacyjnego. W ramach dodatkowego porównania tabela została uzupełniona o procent prawidłowych rozwiązań, który średnio uzyskałby klasyfikator losowy. Na rysunku 4 przedstawiono macierze pomyłek prezentujące wyniki weryfikacji.

Klasyfikator	Skuteczność predykcji
klasyfikator losowy	9,09%
klasyfikator A	16,92%
klasyfikator B	8,46%
klasyfikator C	23,85%

Tabela 3: Klasyfikatory i skuteczność ich predykcji



Rysunek 4: Macierze pomyłek prezentujące wyniki weryfikacji skuteczności bazującego na dodatkowym zbiorze testowym, dla: klasyfikatora A (A), klasyfikatora B (B), klasyfikatora C (C). Na osi poziomej predykowane etykiety obrazów, na osi pionowej prawdziwe wartości, etykiety w kolejności pokazanej w tabeli 1

## **4 Wnioski**

Co pokazała weryfikacja skuteczności, żaden z zaproponowanych klasyfikatorów nie nadaje się do praktycznego zastosowania. Trywialna struktura sieci neuronowej, zbyt mała ilość danych uczących, zbyt mała liczba epok to czynniki, które wpłynęły na ostatecznie bardzo niską skuteczność klasyfikatorów A i C. Biorąc pod uwagę samodzielnią pracę, ograniczenia sprzętowe oraz ograniczenia dotyczące zdobycia danych niemożliwa jest implementacja własnej sieci neuronowej o bardzo wysokiej skuteczności.

## **A Dodatek**

Kody źródłowe umieszczone zostały na dysku google:

[https://drive.google.com/drive/folders/1hQLJUi2UFsqbEZfFiMDWvshfXJo4thXk?usp=share\\_link](https://drive.google.com/drive/folders/1hQLJUi2UFsqbEZfFiMDWvshfXJo4thXk?usp=share_link).